



Corso di Laurea in Informatica

CALCOLO SCIENTIFICO

Docente del corso

Prof. Dajana Conte

Aritmetica floating point - Parte 2

Monegato paragrafi 1.1-1.2

Quarteroni: paragrafi 1.1 ed 1.2

Rappresentazione dei numeri reali su calcolatore

Un qualunque numero reale a ammette una rappresentazione in base N della forma

$$a = p N^q$$

con

- p reale $\rightarrow$ **mantissa**
- q intero (<0 , $=0$ oppure >0) $\rightarrow$ **caratteristica**
- N **base**

Ogni numero reale si può rappresentare come coppia (**mantissa**, **caratteristica**), fissata la base N del sistema di numerazione.

Rappresentazione dei numeri reali su calcolatore

Un qualunque numero reale a ammette una rappresentazione in base N della forma

$$a = p N^q$$

Questa rappresentazione non è unica. Infatti

$$a = p N^q = (pN) N^{q-1} = \frac{p}{N} N^{q+1}$$

Esempio:

$$\begin{aligned} 123 &= 123 * 10^0 = 12,3 * 10^1 \\ &= 1,23 * 10^2 = 0,123 * 10^3 = 0,0123 * 10^4 \end{aligned}$$

Rappresentazione dei numeri reali su calcolatore

La rappresentazione adottata sul calcolatore è quella **normalizzata**, ovvero tale che

$$N^{-1} \leq |p| < 1$$

e cioè $|p| = 0.p_1 p_2 \dots$ con $p_1 \neq 0$

Nell'esempio precedente l'unica rappresentazione normalizzata di 123 è $0,123 \cdot 10^3$. Le altre rappresentazioni hanno una mantissa in modulo > 1 , oppure < 0.1 (l'ultimo caso).

$$\begin{aligned} 123 &= 123 \cdot 10^0 = 12,3 \cdot 10^1 \\ &= 1,23 \cdot 10^2 = 0,123 \cdot 10^3 = 0,0123 \cdot 10^4 \end{aligned}$$

Se a è un numero reale non di macchina, esso deve essere approssimato mediante un numero di macchina, cioè, detto $M=M(N,t,L,U)$ l'insieme dei numeri di macchina

$$a \in \mathfrak{R} - M \rightarrow \bar{a} = fl(a) \in M$$

$$a = p N^q \rightarrow \bar{a} = \bar{p} N^q$$

Come si sceglie $\bar{p}$?

Troncamento:

$$|p - \bar{p}| \leq N^{-t},$$

$$p = 0.p_1 p_2 \dots p_t p_{t+1} \dots, \quad \bar{p} = 0.p_1 p_2 \dots p_t.$$

Arrotondamento:

$$|p - \bar{p}| \leq \frac{1}{2} N^{-t}$$

$$\bar{p} = 0.p_1 p_2 \dots p_t \quad \text{se } 0 \leq p_{t+1} < N/2,$$

$$\bar{p} = 0.p_1 p_2 \dots p_t + N^{-t} \quad \text{se } p_{t+1} \geq N/2$$

Errore di arrotondamento

- Ricapitoliamo: abbiamo un numero reale a e la sua rappresentazione in macchina che indichiamo con $\bar{a}$
- Vogliamo una misura di **errore**, cioè vogliamo capire di quanto il valore esatto si discosti da quello approssimato.
- **Errore assoluto** $|a - \bar{a}|$
- **Errore relativo** $\left| \frac{a - \bar{a}}{a} \right|$

Monegato paragrafo 1.3

Errore di arrotondamento

Teorema

$a = p N^q$ numero reale

$\bar{a} = \bar{p} N^q$ numero di macchina


$$\left| \frac{a - \bar{a}}{a} \right| \leq \left(\frac{1}{2} \right) N^{1-t}$$

Dimostrazione

Errore assoluto di arrotondamento (con t bit significativi per la mantissa):

$$|p - \bar{p}| \leq \left(\frac{1}{2} \right) N^{-t}, \quad |a - \bar{a}| \leq \left(\frac{1}{2} \right) N^{q-t}$$

Errore relativo di arrotondamento:

$$|a| = |p N^q| = |p| N^q \geq N^{-1} N^q = N^{q-1}, \quad \frac{1}{|a|} \leq \frac{1}{N^{q-1}}$$

$$\left| \frac{a - \bar{a}}{a} \right| \leq \frac{|a - \bar{a}|}{N^{q-1}} \leq \left(\frac{1}{2} \right) N^{q-t} N^{1-q} = \left(\frac{1}{2} \right) N^{1-t} \quad \blacksquare$$

$\left(\frac{1}{2} \right) N^{1-t}$ è la precisione di macchina = eps

Errore di arrotondamento

$\left(\frac{1}{2}\right) N^{1-t}$ è la precisione di macchina = eps

$M=M(N,t,L,U)$ numeri macchina consideriamo $N=2$

	segno	caratteristica	mantissa
Semplice precisione: 32 bit	1bit	8 bit	23bit
Doppia precisione :64 bit	1 bit	11 bit	52 bit

- Secondo lo standard IEEE754 (standard di rappresentazione) dei numeri in virgola mobile, utilizzando 8 byte per la rappresentazione dei numeri di macchina in doppia precisione si ha $N=2$, $t = 52$, $L=-1023$, $U=1024$,

$$eps = \frac{1}{2} 2^{1-52} = 2^{-52} \approx 2.22 \cdot 10^{-16}$$

- Questo valore esprime la **massima accuratezza possibile** (ossia il minimo errore) che potremo ottenere dalle nostre risposte numeriche.