




PROBLEMA DEL PAGE RANK DI GOOGLE PARTE 1

1

MATEMATICA DEL WEB: GOOGLE E PAGE RANK

Larry Page e Sergey Brin, specializzandi in Informatica a Stanford, hanno inventato il motore di ricerca più famoso.

- Page creò un programma per sapere quali siti contenevano un link ad una certa pagina (BackRub).
- Pensando alla bibliometria (*valutazione di un articolo sulla base delle sue citazioni*), Page e Brin idearono un programma per misurare l'importanza di una pagina web, contando quante altre pagine rimandano ad essa.

Problema: ordinare le pagine presenti sul web in base alla loro importanza (**page rank**)

PAGE RANK

- L'importanza di una pagina è legata alle sue **connessioni** (e non al suo contenuto)
- L'importanza di una pagina è trasferita alle pagine a cui essa punta
- L'importanza di una pagina è data dalla somma delle frazioni di importanza delle pagine che ad essa puntano

ovvero

Io sono importante se frequento persone importanti

Se io sono importante, allora anche le persone che frequento sono importanti

MATRICE DI CONNETTIVITA'

- Numeriamo le pagine del web da 1 a n , e definiamo la matrice di connettività $G = (g_{ij})$, con

$$g_{ij} = 1 \text{ se c'è un link dalla pagina } j \text{ alla pagina } i$$
$$g_{ij} = 0 \text{ altrimenti.}$$

- Indichiamo con

x_i importanza della pagina i

- c_j numero di link che partono dalla pagina j , pari a $\sum_{i=1}^n g_{ij}$
- r_i numero di link che puntano alla pagina i , pari a $\sum_{j=1}^n g_{ij}$

ESEMPIO DI MATRICE DI CONNETTIVITÀ


$$H = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix} \quad G=H^T = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

①

②

③

④



PAGE RANK (CONT.)

Per l'importanza della pagina i risulta

$$x_i = g_{i1} \frac{x_1}{c_1} + g_{i2} \frac{x_2}{c_2} + \dots + g_{in} \frac{x_n}{c_n}$$

Sistema lineare $n \times n$ (*sparso*): le soluzioni forniscono il livello di importanza delle singole pagine.

Il Page Rank viene calcolato una volta al mese (su 10^9 pagine)



PAGE RANK (CONT.)

Per l'importanza della pagina i risulta

$$x_i = g_{i1} \frac{x_1}{c_1} + g_{i2} \frac{x_2}{c_2} + \dots + g_{in} \frac{x_n}{c_n}$$

Sistema lineare $n \times n$ (*sparso*): le soluzioni forniscono il livello di importanza delle singole pagine.

Il sistema può essere scritto nella forma:

$$(I - GD)x = 0$$

dove I è la matrice identità di dimensione n :

$$I = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & \dots \\ \dots & \dots & \dots & 0 \\ 0 & \dots & 0 & 1 \end{pmatrix} \quad x = \begin{pmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{pmatrix} \quad D = \begin{pmatrix} \frac{1}{c_1} & 0 & \dots & 0 \\ 0 & \frac{1}{c_2} & \dots & \dots \\ \dots & \dots & \dots & 0 \\ 0 & \dots & 0 & \frac{1}{c_n} \end{pmatrix}$$

MA NON SEMPRE ESISTE SOLUZIONE NON BANALE!!!!



PAGE RANK (CONT.)

Pertanto il sistema viene modificato e l'equazione di Google è:

$$(1) \quad x_i = p \left(g_{i1} \frac{x_1}{c_1} + g_{i2} \frac{x_2}{c_2} + \dots + g_{in} \frac{x_n}{c_n} \right) + \frac{1}{n} (1-p)$$

importanza minima
di una pagina

con ***p*** parametro tra 0 e 1 (di solito $p=0.85$), che indica la percentuale di importanza che transita da una pagina all'altra (*damping factor*).

Il sistema può essere scritto nella forma:

$$(I - pGD)x = \delta e$$

dove *I* e *D* sono state definite nella slide precedente, $\delta = \frac{1-p}{n}$, $e = \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}$

Il Page Rank viene calcolato una volta al mese (su 10^9 pagine)

PAGE RANK : SISTEMA LINEARE

- Pertanto l'equazione di Google è un sistema del tipo

$$(I - pGD)x = \delta e$$

$$Ax = b$$

La cui soluzione può essere determinata normalmente con il metodo di eliminazione di Gauss con pivoting parziale.

Si dimostra infatti che $\det(I - pGD) \neq 0$ se $0 < p < 1$, e che l'unica soluzione del sistema verifica

$$0 \leq x_i \leq 1 \quad \forall i \quad \sum_{i=1}^n x_i = 1$$