




ALGORITMO PAGE RANK DI GOOGLE PARTE 2

1

MATRICE DI CONNETTIVITA'

- Numeriamo le pagine del web da **1** a **n** , e definiamo la matrice di connettività **$G = (g_{ij})$** , con

$g_{ij} = 1$ se c'è un link dalla pagina j alla pagina i
 $g_{ij} = 0$ altrimenti.

- Indichiamo con

x_i importanza della pagina i

- **c_j** numero di link che partono dalla pagina j , pari a $\sum_{i=1}^n g_{ij}$
- **r_i** numero di link che puntano alla pagina i , pari a $\sum_{j=1}^n g_{ij}$

PAGE RANK : SISTEMA LINEARE

Sistema lineare $n \times n$ (*sparso*): le n componenti della soluzione forniscono il livello di importanza delle singole pagine (x_i =importanza della pagina i):

$$(I - pGD)x = \delta e \quad (1)$$

$$I = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & \dots \\ \dots & \dots & \dots & 0 \\ 0 & \dots & 0 & 1 \end{pmatrix} \quad x = \begin{pmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{pmatrix} \quad D = \begin{pmatrix} \frac{1}{c_1} & 0 & \dots & 0 \\ 0 & \frac{1}{c_2} & \dots & \dots \\ \dots & \dots & \dots & 0 \\ 0 & \dots & 0 & \frac{1}{c_n} \end{pmatrix} \quad \delta = \frac{1-p}{n} \quad e = \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}$$

di solito $p=0.85$

Si dimostra infatti che $\det(I-pGD) \neq 0$ se $0 < p < 1$, e che l'unica soluzione del sistema verifica

- $0 \leq x_i \leq 1 \quad \forall i$
- $\sum_{i=1}^n x_i = 1$ ovvero $e^T x = 1$ oppure anche $\|x\|_1 = 1$

PAGE RANK: PROBLEMA AGLI AUTOVALORI

Tenendo conto che $e^T x = 1$, si ha

$$(I - pGD)x = \delta e \Leftrightarrow x - pGDx = \delta e e^T x \Leftrightarrow x = pGDx + \delta e e^T x \Leftrightarrow x = Ax$$

dove A è la matrice:

$$A = pGD + \delta e e^T \quad \text{ i cui elementi sono } a_{ij} = p \frac{g_{ji}}{c_j} + \delta$$

Allora il sistema (1) equivale al sistema

$$x = Ax \quad (2) \quad \text{ con } \|x\|_1 = 1$$

Risolvere il sistema (2) equivale a trovare l'autovettore di norma 1 unitaria corrispondente all'autovalore 1 (se esiste).

A non è sparsa, ma è la modifica di una matrice sparsa; la maggior parte dei suoi elementi ha un valore piccolissimo tra 0 e 1; la somma di ciascuna colonna è 1. Tale matrice si chiama **stocastica**.

MATRICI STOCASTICHE E CALCOLO DI $\mathbf{x}$

Teorema.

Sia $\mathbf{A}$ una matrice stocastica per righe, allora $\rho(\mathbf{A}) = 1$.

Da ciò si evince che:

- 1) $\mathbf{Ax} = \mathbf{x}$ ha soluzione non banale in quanto 1 è autovalore di $\mathbf{A}$;
- 2) Dato che 1 è l'autovalore di massimo modulo possiamo calcolare $\mathbf{x}$ usando il metodo delle potenze.



NOTE ALGORITMICHE

- Dalla matrice di connettività si escludono i link autoreferenziali, e quindi si pone:

$$g_{ii} = 0$$

- Poiché

$$\sum_{i=1}^n x_i = 1 \quad \text{e} \quad x_i \geq 0$$

nel metodo delle potenze conviene considerare l'autovettore della matrice A normalizzato rispetto alla norma 1:

$$\|x\|_1 = \sum_{i=1}^n |x_i| = 1$$

NOTE ALGORITMICHE: CASO $c_j = 0$

ossia dalla pagina j non partono link

Si fa in modo che l'importanza della pagina j sia uniformemente distribuita a tutte le pagine:

- Si pone $g_{ij} = 1$ per ogni i diverso da j
- perciò si ha $c_j = n-1$, e di conseguenza nell'equazione di Google risulta:

$$x_i = p \left(g_{i1} \frac{x_1}{c_1} + \cdots + \frac{x_j}{n-1} + \cdots + g_{in} \frac{x_n}{c_n} \right) + \frac{1}{n} (1 - p), \forall i$$

da cui è evidente che ad ogni pagina i è trasferita la stessa quota di importanza della pagina j

MATRICI SPARSE IN MATLAB

S = sparse(A) converte una matrice A dal formato pieno al formato sparso

A = full(S) converte una matrice S dal formato sparso al formato pieno

n = nnz(S) numero di elementi non nulli della matrice S

spy(S) Il comando `spy(S)` permette di visualizzare la sparsità di una matrice generando un grafico nel quale sono evidenziati con un punto solo gli elementi di S che sono diversi da zero.

COSTRUZIONE DELLA MATRICE DI CONNETTIVITA'

1° passo: MATRICE DI CONNETTIVITA'

Consideriamo un sito web, ad esempio:


<http://www.microsoft.com>

La funzione **surfer** ci permette di scaricare una porzione della rete, immettendo una pagina da cui partire e il numero di nodi da considerare. Come output otteniamo il vettore U , che contiene gli indirizzi dei siti visitati e G la matrice sparsa, il cui generico elemento G_{ij} vale 1 se la pagina U_j punta verso la pagina U_i , zero altrimenti.

`[U,G] = surfer('https://www.harvard.edu',150);`

MATRICE DI CONNETTIVITÀ: GRAFO

○ spy plot di G



Gli elementi diversi da zero sono riportati con un punto blu sul grafico.

ALGORITMO PAGE RANK

1° passo: Costruire la matrice di connettività G relativa a un URL tramite la funzione `surfer`. Esempio:

`[U,G] = surfer('http://www.microsoft.com/', 150)`

Togliere LINK AUTOREFERENZIALI e COLONNE NULLE

2° passo: Costruire la matrice A $\rightarrow A = pGD + \delta ee^T$

3° passo: Metodo delle potenze per calcolare l'autovettore di massimo modulo, o risoluzione di un sistema lineare

$$A = I - pGD$$
$$b = \delta e$$

