

MACHINE LEARNING & ANALISI NUMERICA

La diffusione delle tecniche di Machine e Deep Learning ha coinvolto anche il settore dell'Analisi Numerica.



MACHINE LEARNING – INTRODUZIONE

MACHINE LEARNING

Il ML è una disciplina scientifica che si occupa della creazione e dello studio di algoritmi capaci di risolvere un PROBLEMA apprendendo dall'esperienza (DATI).

Problema: Identificare un gatto!

Approccio classico:

- Spiegare nel dettaglio come identificare un gatto in un insieme di vari animali descrivendo ogni dettaglio necessario.

Approccio di Machine Learning:

- Collezionare immagini (DATI) di vari animali etichettando le immagini che comprendono gatti.



BIBLIOGRAFIA:

Hastie, T., Tibshirani, R., Friedman, J. H., & Friedman, J. H. (2009).
The elements of statistical learning: data mining, inference, and prediction

STRUTTURA DEI DATI – SUPERVISED VS UNSUPERVISED

SUPERVISED

FEATURES

LABEL

x_1



$y_1 = 1$

x_2



$y_2 = 1$

x_3




$y_3 = 0$

x



$y = ?$

UNSUPERVISED



STRUTTURA DEI DATI – SUPERVISED VS UNSUPERVISED

SUPERVISED

DATASET

$$T = \{(x_1, y_1), \dots, (x_m, y_m)\}$$


CON

$x_1, \dots, x_m \in \mathbb{R}^D$ VETTORI DELLE FEATURES

$y_1, \dots, y_m \in \mathbb{R}$ LABELS

OBIETTIVO

Individuare una funzione f tale che
 $f(x_i) \approx y_i \quad i = 1, \dots, m$



UNSUPERVISED

DATASET


$$T = \{x_1, \dots, x_m\}$$

CON

$x_1, \dots, x_m \in \mathbb{R}^D$ VETTORI DELLE FEATURES

OBIETTIVO

Dividere i dati in insiemi definiti
CLUSTER



SUPERVISED LEARNING – MODELLO LINEARE


Bisogna individuare il modello adeguato per l'approssimazione dei dati

$$f(x) = \sum_{i=1}^n w_i \phi_i(x), \quad w_i \in \mathbb{R}, \quad \phi_i: \mathbb{R}^D \mapsto \mathbb{R}, \quad i = 1, \dots, n, \quad f: \mathbb{R}^D \mapsto \mathbb{R}$$

Scegliamo

- $D = 1$
- $n = 2$
- $w_1, w_2 \in \mathbb{R}$
- $\phi_1(x) = 1, \quad \phi_2(x) = x$

$$f(x) = w_1 \phi_1(x) + w_2 \phi_2(x) = w_1 + w_2 x$$



$$f(x_i) \approx y_i, \quad i = 1, \dots, m$$

SUPERVISED LEARNING – MODELLO LINEARE


Bisogna individuare il modello adeguato per l'approssimazione dei dati

$$f(x) = \sum_{i=1}^n w_i \phi_i(x), \quad w_i \in \mathbb{R}, \quad \phi_i: \mathbb{R}^D \mapsto \mathbb{R}, \quad i = 1, \dots, n, \quad f: \mathbb{R}^D \mapsto \mathbb{R}$$


Scegliamo

- $D = 1$
- $n = 3$
- $w_1, w_2, w_3 \in \mathbb{R}$
- $\phi_1(x) = 1, \phi_2(x) = x, \phi_3(x) = x^2$

$$f(x) = w_1 \phi_1(x) + w_2 \phi_2(x) + w_3 \phi_3(x) = w_1 + w_2 x + w_3 x^2$$



$$f(x_i) \approx y_i, \quad i = 1, \dots, m$$





SUPERVISED LEARNING – MODELLO LINEARE

Bisogna individuare il modello adeguato per l'approssimazione dei dati

$$f(x) = \sum_{i=1}^n w_i \phi_i(x), \quad w_i \in \mathbb{R}, \quad \phi_i: \mathbb{R}^D \mapsto \mathbb{R}, \quad i = 1, \dots, n, \quad f: \mathbb{R}^D \mapsto \mathbb{R}$$

Come selezionare i coefficienti $w_1, \dots, w_n$?





SUPERVISED LEARNING – LIMITI DEL MODELLO LINEARE



- COME SELEZIONARE ϕ_i ?



- I MODELLI LINEARI SONO SEMPRE IDONEI?



SUPERVISED LEARNING – LIMITI DEL MODELLO LINEARE



- COME SELEZIONARE ϕ_i ?



- I MODELLI LINEARI SONO SEMPRE IDONEI?



MODELLI NON LINEARI
DEEP LEARNING

COSA È IL DEEP LEARNING?

Con il termine Deep Learning è una sottocategoria del Machine Learning basata sulle Reti Neurali Artificiali

Le Reti Neurali Artificiali sono ispirate alle Reti Neurali biologiche.



COSA È IL DEEP LEARNING?

DATASET

$$T = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

CON

$x_1, \dots, x_m \in \mathbb{R}^D$ VETTORI DELLE FEATURES

$y_1, \dots, y_m \in \mathbb{R}^k$ LABELS

OBIETTIVO

Individuare una funzione f tale che

$$f(x_i) \approx y_i \quad i = 1, \dots, m$$

$i = 1, \dots, m$

$(x_i)_1 \rightarrow \bigcirc$ NEURONE

$(x_i)_2 \rightarrow \bigcirc$ NEURONE

$\vdots$
 $\vdots$

$(x_i)_D \rightarrow \bigcirc$ NEURONE

LAYER 1
DI INPUT

COSA È IL DEEP LEARNING?

DATASET

$$T = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

CON

$x_1, \dots, x_m \in \mathbb{R}^D$ VETTORI DELLE FEATURES

$y_1, \dots, y_m \in \mathbb{R}^k$ LABELS

OBIETTIVO

Individuare una funzione f tale che
 $f(x_i) \approx y_i \quad i = 1, \dots, m$

$i = 1, \dots, m$

$(x_i)_1 \rightarrow \bigcirc$

$(x_i)_2 \rightarrow \bigcirc$

$\vdots$
 $\vdots$

$(x_i)_D \rightarrow \bigcirc$

LAYER 1
DI INPUT

$\bullet \rightarrow (f(x_i))_1$

$\bullet \rightarrow (f(x_i))_2$

$\vdots$
 $\vdots$

$\bullet \rightarrow (f(x_i))_k$

LAYER
DI OUTPUT

COSA È IL DEEP LEARNING?

DATASET

$$T = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

CON

$x_1, \dots, x_m \in \mathbb{R}^D$ VETTORI DELLE FEATURES

$y_1, \dots, y_m \in \mathbb{R}^k$ LABELS

OBIETTIVO

Individuare una funzione f tale che
 $f(x_i) \approx y_i \quad i = 1, \dots, m$

$i = 1, \dots, m$

$(x_i)_1 \rightarrow \bigcirc$

$(x_i)_2 \rightarrow \bigcirc$

$\vdots$
 $\vdots$

$(x_i)_D \rightarrow \bigcirc$



$\vdots$



$\vdots$



$\vdots$



$\vdots$



$\rightarrow (f(x_i))_1$

$\rightarrow (f(x_i))_2$

$\vdots$

$\rightarrow (f(x_i))_k$

LAYER 1
DI INPUT

LAYER 2
NASCOSTO

LAYER 3
NASCOSTO

LAYER 4
NASCOSTO

LAYER 5
DI OUTPUT

COSA È IL DEEP LEARNING?

DATASET

$$T = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

CON


$x_1, \dots, x_m \in \mathbb{R}^D$ VETTORI DELLE FEATURES

$y_1, \dots, y_m \in \mathbb{R}^k$ LABELS

OBIETTIVO

Individuare una funzione f tale che
 $f(x_i) \approx y_i \quad i = 1, \dots, m$

$i = 1, \dots, m$



LAYER 1
DI INPUT

LAYER 2
NASCOSTO

LAYER 3
NASCOSTO

LAYER 4
NASCOSTO

LAYER 5
DI OUTPUT

DEEP LEARNING – UN ESEMPIO PRATICO


DATASET:

Il dataset describe i siti di trivellazione per individuare il petrolio

I dati sono etichettati (SUPERVISED LEARNING)

○ → Siti con esito favorevole (CATEGORIA A)

× → Siti con esito sfavorevole (CATEGORIA B)



FEATURES	CAMPIONI	1	2	3	4	5	6	7	8	9	10
	ASCISSA	0.1	0.3	0.1	0.6	0.4	0.6	0.5	0.9	0.4	0.7
	ORDINATA	0.1	0.4	0.5	0.9	0.2	0.3	0.6	0.2	0.4	0.6
LABEL	CATEGORIA	A	A	A	A	A	B	B	B	B	B

BIBLIOGRAFIA:


Higham, C.F., Higham, D.J. (2019) Deep learning: An introduction for applied mathematicians.

DEEP LEARNING – UN ESEMPIO PRATICO

DATASET:

Il dataset descrive i siti di trivellazione per individuare il petrolio

I dati sono etichettati (SUPERVISED LEARNING)



$$y_i = \begin{cases} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in \mathbb{R}^2, & \text{se } x \text{ è nella categoria A } \bigcirc \\ \begin{bmatrix} 0 \\ 1 \end{bmatrix} \in \mathbb{R}^2, & \text{se } x \text{ è nella categoria B } \times \end{cases}$$

CAMPIONI		1	2	3	4	5	6	7	8	9	10
FEATURES	ASCISSA	0.1	0.3	0.1	0.6	0.4	0.6	0.5	0.9	0.4	0.7
	ORDINATA	0.1	0.4	0.5	0.9	0.2	0.3	0.6	0.2	0.4	0.6
LABEL	CATEGORIA	A	A	A	A	A	B	B	B	B	B

BIBLIOGRAFIA:


Higham, C.F., Higham, D.J. (2019) Deep learning: An introduction for applied mathematicians.

MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3(f_2(x)) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.



x_1
 x_2
 $\vdots$
 x_{10}


CAMPIONI	1	2	...	10
ASCISSA	0.1	0.3	...	0.7
ORDINATA	0.1	0.4	...	0.6
CATEGORIA	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	...	$\begin{bmatrix} 0 \\ 1 \end{bmatrix}$

MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3 \left(f_2(x) \right) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.



x_1
 x_2
 $\vdots$
 x_{10}

$$f(x_1) \approx y_1 \in \mathbb{R}^2$$

$$f(x_2) \approx y_2 \in \mathbb{R}^2$$

$\vdots$

$$f(x_{10}) \approx y_{10} \in \mathbb{R}^2$$


CAMPIONI	1	2	...	10
ASCISSA	0.1	0.3	...	0.7
ORDINATA	0.1	0.4	...	0.6
CATEGORIA	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	...	$\begin{bmatrix} 0 \\ 1 \end{bmatrix}$

MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3 \left(f_2(x) \right) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.



$$x_1 = y_1^{(1)} \in \mathbb{R}^2 \rightarrow y_1^{(2)} \in \mathbb{R}^2 \rightarrow y_1^{(3)} \in \mathbb{R}^3 \rightarrow y_1^{(4)} = f(x_1) \approx y_1 \in \mathbb{R}^2$$

$$x_2 \quad \quad \quad f(x_2) \approx y_2 \in \mathbb{R}^2$$

$\vdots$

$\vdots$

x_{10}

$$f(x_{10}) \approx y_{10} \in \mathbb{R}^2$$


CAMPIONI	1	2	...	10
ASCISSA	0.1	0.3	...	0.7
ORDINATA	0.1	0.4	...	0.6
CATEGORIA	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	...	$\begin{bmatrix} 0 \\ 1 \end{bmatrix}$

MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3(f_2(x)) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.



$$x_1 = y_1^{(1)} \in \mathbb{R}^2 \rightarrow y_1^{(2)} \in \mathbb{R}^2 \rightarrow y_1^{(3)} \in \mathbb{R}^3 \rightarrow y_1^{(4)} = f(x_1) \approx y_1 \in \mathbb{R}^2$$

$$x_2 = y_2^{(1)} \in \mathbb{R}^2 \rightarrow y_2^{(2)} \in \mathbb{R}^2 \rightarrow y_2^{(3)} \in \mathbb{R}^3 \rightarrow y_2^{(4)} = f(x_2) \approx y_2 \in \mathbb{R}^2$$

$$\vdots \quad \vdots \quad \quad \quad \vdots \quad \quad \quad \vdots \quad \quad \quad \vdots$$

$$x_{10} = y_{10}^{(1)} \in \mathbb{R}^2 \rightarrow y_{10}^{(2)} \in \mathbb{R}^2 \rightarrow y_{10}^{(3)} \in \mathbb{R}^3 \rightarrow y_{10}^{(4)} = f(x_{10}) \approx y_{10} \in \mathbb{R}^2$$


CAMPIONI	1	2	...	10
ASCISSA	0.1	0.3	...	0.7
ORDINATA	0.1	0.4	...	0.6
CATEGORIA	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$	...	$\begin{bmatrix} 0 \\ 1 \end{bmatrix}$

MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3(f_2(x)) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.




$$y^{(1)} = x, \quad x \in \mathbb{R}^2$$

MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3(f_2(x)) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.




$$y^{(1)} = x, \quad x \in \mathbb{R}^2$$

$$y^{(2)} = f_2(y^{(1)}) = \sigma(W^{[2]}y^{(1)} + b_2) \in \mathbb{R}^2, \quad W^{[2]} \in \mathbb{R}^{2 \times 2}, b_2 \in \mathbb{R}^2$$

SIGMOIDE

$$\sigma(\alpha) = \frac{1}{1 + e^{-\alpha}}$$

$$\sigma'(\alpha) = \sigma(\alpha)(1 - \sigma(\alpha))$$




MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3(f_2(x)) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.



$$y^{(1)} = x, \quad x \in \mathbb{R}^2$$


$$y^{(2)} = f_2(y^{(1)}) = \sigma(W^{[2]}y^{(1)} + b_2) \in \mathbb{R}^2, \quad W^{[2]} \in \mathbb{R}^{2 \times 2}, b_2 \in \mathbb{R}^2$$

$$y^{(3)} = f_3(y^{(2)}) = \sigma(W^{[3]}y^{(2)} + b_3) \in \mathbb{R}^3, \quad W^{[3]} \in \mathbb{R}^{3 \times 2}, b_3 \in \mathbb{R}^3$$

SIGMOIDE

$$\sigma(\alpha) = \frac{1}{1 + e^{-\alpha}}$$

$$\sigma'(\alpha) = \sigma(\alpha)(1 - \sigma(\alpha))$$




MODELLI NON LINEARI – IL DEEP LEARNING

Nel Deep Learning la funzione f è definita mediante una composizione di funzioni

$$f(x) = f_4 \left(f_3(f_2(x)) \right)$$

con le funzioni f_2, f_3, f_4 associate all'utilizzo dei livelli di una Rete Neurale Artificiale.



$$y^{(1)} = x, \quad x \in \mathbb{R}^2$$

$$y^{(2)} = f_2(y^{(1)}) = \sigma(W^{[2]}y^{(1)} + b_2) \in \mathbb{R}^2, \quad W^{[2]} \in \mathbb{R}^{2 \times 2}, b_2 \in \mathbb{R}^2$$


$$y^{(3)} = f_3(y^{(2)}) = \sigma(W^{[3]}y^{(2)} + b_3) \in \mathbb{R}^3, \quad W^{[3]} \in \mathbb{R}^{3 \times 2}, b_3 \in \mathbb{R}^3$$

$$y^{(4)} = f_4(y^{(3)}) = \sigma(W^{[4]}y^{(3)} + b_4) \in \mathbb{R}^2, \quad W^{[4]} \in \mathbb{R}^{2 \times 3}, b_4 \in \mathbb{R}^2$$

SIGMOIDE

$$\sigma(\alpha) = \frac{1}{1 + e^{-\alpha}}$$

$$\sigma'(\alpha) = \sigma(\alpha)(1 - \sigma(\alpha))$$



DEEP LEARNING – UN ESEMPIO PRATICO

FASE 1 L'obiettivo è determinare i parametri della funzione
$$f(x) = f_4(f_3(f_2(x))) = \sigma(W^{[4]}\sigma(W^{[3]}\sigma(W^{[2]}x + b_2) + b_3) + b_4) \in \mathbb{R}^2$$

che consentono di minimizzare la LOSS FUNCTION

$$Loss(W^{[2]}, W^{[3]}, W^{[4]}, b_2, b_3, b_4) = \frac{1}{10} \sum_{i=1}^{10} \frac{1}{2} \|y_i - f(x_i)\|_2^2$$

per individuare i parametri



$$W^{[2]} \in \mathbb{R}^{2 \times 2}, b_2 \in \mathbb{R}^2$$

$$W^{[3]} \in \mathbb{R}^{3 \times 2}, b_3 \in \mathbb{R}^3$$

$$W^{[4]} \in \mathbb{R}^{2 \times 3}, b_4 \in \mathbb{R}^2$$

FASE 2 Una volta individuati, la classificazione su nuovi dati x avverrà imponendo


$$f(x) = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix} \in \mathbb{R}^2 \quad \longrightarrow \quad y = \begin{cases} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in \mathbb{R}^2 & \text{se } z_1 \geq z_2 \quad \text{○} \\ \begin{bmatrix} 0 \\ 1 \end{bmatrix} \in \mathbb{R}^2 & \text{se } z_2 > z_1 \quad \text{×} \end{cases}$$



DISCESA DEL GRADIENTE

FASE 1 Sia $p \in \mathbb{R}^s$ il vettore degli s parametri e $L(p)$ la LOSS FUNCTION

$$L(p) = \text{Loss}(W^{[2]}, W^{[3]}, W^{[4]}, b_2, b_3, b_4) = \frac{1}{10} \sum_{i=1}^{10} \frac{1}{2} \|y_i - f(x_i)\|_2^2$$



DISCESA DEL GRADIENTE

FASE 1 Sia $p \in \mathbb{R}^s$ il vettore degli s parametri e $L(p)$ la LOSS FUNCTION

$$L(p) = \text{Loss}(W^{[2]}, W^{[3]}, W^{[4]}, b_2, b_3, b_4) = \frac{1}{10} \sum_{i=1}^{10} \frac{1}{2} \|y_i - f(x_i)\|_2^2$$


L'obiettivo consiste nell'individuare il punto di MINIMO
 $p^* \in \mathbb{R}^s$ tale che

$$L(p^*) \leq L(p), \quad p \in \mathbb{R}^s$$

A tale scopo si sfrutta l'algoritmo della Discesa del Gradiente:

1. Selezionare $p^{(0)}$
2. Porre $p^{(k+1)} = p^{(k)} + \Delta p^{(k)}$

In modo tale che $\lim_{k \rightarrow +\infty} p^{(k)} = p^*$



DISCESA DEL GRADIENTE

FASE 1 Sia $p \in \mathbb{R}^s$ il vettore degli s parametri e $L(p)$ la LOSS FUNCTION

$$L(p) = \text{Loss}(W^{[2]}, W^{[3]}, W^{[4]}, b_2, b_3, b_4) = \frac{1}{10} \sum_{i=1}^{10} \frac{1}{2} \|y_i - f(x_i)\|_2^2$$

L'obiettivo consiste nell'individuare il punto di MINIMO $p^* \in \mathbb{R}^s$ tale che

$$L(p^*) \leq L(p), \quad p \in \mathbb{R}^s$$

A tale scopo si sfrutta l'algoritmo della Discesa del Gradiente:

1. Selezionare $p^{(0)}$

2. Porre $p^{(k+1)} = p^{(k)} + \Delta p^{(k)}$


In modo tale che $\lim_{k \rightarrow +\infty} p^{(k)} = p^*$

COME SCEGLIERE $\Delta p^{(k)}$?

$$\Delta p^{(k)} = -\eta \nabla L(p^{(k)})$$

con Gradiente

$$(\nabla L(p))_r = \frac{\partial L}{\partial p_r}(p), \quad r = 1, \dots, s$$



DISCESA DEL GRADIENTE- SCEGLIERE Δp^k

Vogliamo individuare $\Delta p^{(k)}$ in modo tale che

$$L(p^{(k+1)}) < L(p^{(k)}),$$

quindi, sviluppiamo in serie di Taylor troncata al primo termine la LOSS FUNCTION

$$L(p^{(k+1)}) = L(p^{(k)} + \Delta p^{(k)}) \approx L(p^{(k)}) + \sum_{r=1}^s \frac{\partial L}{\partial p_r}(p^{(k)}) \Delta p_r^{(k)}$$

che in forma compatta diventa

$$L(p^{(k+1)}) \approx L(p^{(k)}) + \langle \nabla L(p^{(k)}), \Delta p^{(k)} \rangle,$$

ovvero

$$L(p^{(k+1)}) - L(p^{(k)}) \approx \langle \nabla L(p^{(k)}), \Delta p^{(k)} \rangle.$$

Poiché vogliamo che valga la relazione $L(p^{(k+1)}) < L(p^{(k)})$, dobbiamo imporre

$$\langle \nabla L(p^{(k)}), \Delta p^{(k)} \rangle < 0.$$

Inoltre, vogliamo che sia in modulo il più grande possibile per velocizzare l'individuazione del minimo.



DISCESA DEL GRADIENTE- SCEGLIERE Δp^k

Dalla relazione

$$\langle L(p^{(k)}), \Delta p^{(k)} \rangle = \|\nabla L(p^{(k)})\|_2 \|\Delta p^{(k)}\|_2 \cos(\theta)$$

con θ angolo compreso tra $L(p^{(k)})$ e $\Delta p^{(k)}$.

Si ottiene

$$\langle \nabla L(p^{(k)}), \Delta p^{(k)} \rangle < 0$$

il più grande possibile in modulo se si sceglie $\theta = \pi$,
ovvero $\Delta p^{(k)}$ nella direzione opposta del gradiente

$$\Delta p^{(k)} = -\eta \nabla L(p^{(k)})$$

Si ottiene, quindi, l'aggiornamento

$$p^{(k+1)} = p^{(k)} - \eta \nabla L(p^{(k)})$$

con $\eta \in [0,1]$ definito LEARNING RATE.



BIBLIOGRAFIA:

Quarteroni, F.S.A., Saleri, F., & Gervasio, P. Calcolo scientifico. Springer.

DISCESA DEL GRADIENTE- SCEGLIERE Δp^k

Dalla relazione

$$\langle L(p^{(k)}), \Delta p^{(k)} \rangle = \|\nabla L(p^{(k)})\|_2 \|\Delta p^{(k)}\|_2 \cos(\theta)$$

con θ angolo compreso tra $L(p^{(k)})$ e $\Delta p^{(k)}$.

Si ottiene

$$\langle \nabla L(p^{(k)}), \Delta p^{(k)} \rangle < 0$$

il più grande possibile in modulo se si sceglie $\theta = \pi$,
ovvero $\Delta p^{(k)}$ nella direzione opposta del gradiente

$$\Delta p^{(k)} = -\eta \nabla L(p^{(k)})$$


Si ottiene, quindi, l'aggiornamento

$$p^{(k+1)} = p^{(k)} - \eta \nabla L(p^{(k)})$$


con $\eta \in [0,1]$ definito LEARNING RATE.



Convergence



Divergence



DISCESA DEL GRADIENTE – PROBLEMATICHE

I principali limiti della Discesa del Gradiente sono:

- La necessità di utilizzare tutti i dati per il calcolo dell'aggiornamento

$$p^{(k+1)} = p^{(k)} - \eta \nabla L(p^{(k)})$$

- Il calcolo di derivate di funzioni composte associate all'output della rete

$$f(x) = f_4 \left(f_3 \left(f_2(x) \right) \right) = \sigma \left(W^{[4]} \sigma \left(W^{[3]} \sigma \left(W^{[2]} x + b_2 \right) + b_3 \right) + b_4 \right)$$

i cui parametri

$$W^{[2]} \in \mathbb{R}^{2 \times 2}, b_2 \in \mathbb{R}^2$$

$$W^{[3]} \in \mathbb{R}^{3 \times 2}, b_3 \in \mathbb{R}^3$$

$$W^{[4]} \in \mathbb{R}^{2 \times 3}, b_4 \in \mathbb{R}^2$$

vengono individuati minimizzando la Loss FUNCTION

$$L(p) = \frac{1}{10} \sum_{i=1}^{10} \frac{1}{2} \|y_i - f(x_i)\|_2^2$$

Per superare tali problemi si possono sfruttare:

- Discesa Stocastica del Gradiente



DISCESA STOCASTICA DEL GRADIENTE

Poiché il calcolo del Gradiente della Loss Function

$$L(p) = \frac{1}{10} \sum_{i=1}^{10} L_{x_i}$$
$$L_{x_i} = \frac{1}{2} \|y_i - f(x_i)\|_2^2, \quad i = 1, \dots, 10$$

richiede tutte le componenti del vettore

$$\nabla L(p) = \frac{1}{10} \sum_{i=1}^{10} \nabla L_{x_i}$$

si può modificare la discesa del gradiente con l'algoritmo della Discesa Stocastica del Gradiente approssimando la media con una singola componente.


Sia $i \in \{1, \dots, 10\}$ scelto in modo casuale, l'aggiornamento diventa

$$p^{(k+1)} = p^{(k)} - \eta \nabla L_{x_i}(p^{(k)})$$




DEEP LEARNING – BACKPROPAGATION

L'algoritmo di ottimizzazione scelto va integrato con la tecnica di Backpropagation, che permette il calcolo delle componenti del gradiente della Loss Function per Reti molto complesse.



DEEP LEARNING – L'IDEA ALLA BASE DELLA BACKPROPAGATION

Consideriamo una rete composta da un solo neurone per ogni livello.



$$f(x) = f_4(f_3(f_2(x)))$$
$$f_2(x) = \sigma(W^{[2]}x + b_2) \in \mathbb{R}, \quad W^{[2]}, b_2 \in \mathbb{R}$$
$$f_3(x) = \sigma(W^{[3]}x + b_3) \in \mathbb{R}, \quad W^{[3]}, b_3 \in \mathbb{R}$$
$$f_4(x) = \sigma(W^{[4]}x + b_4) \in \mathbb{R}, \quad W^{[4]}, b_4 \in \mathbb{R}$$

La derivata della funzione che restituisce l'output vale

$$f'(x) = f'_4(f_3(f_2(x))) f'_3(f_2(x)) f'_2(x)$$




BIBLIOGRAFIA:

Higham, C.F., Higham, D.J. (2019) Deep learning: An introduction for applied mathematicians.

DEEP LEARNING – L'IDEA ALLA BASE DELLA BACKPROPAGATION

Consideriamo una rete composta da un solo neurone per ogni livello.



L'algoritmo di Backpropagation ragiona come segue:

1. $f'(x) = f'_4(z)z'$, $z = f_3(f_2(x))$
2. $z' = f'_3(y)y'$, $y = f_2(x)$
3. $y' = f'_2(x)$




BIBLIOGRAFIA:

Higham, C.F., Higham, D.J. (2019) Deep learning: An introduction for applied mathematicians.


DEEP LEARNING – UN ESEMPIO PRATICO

DATASET

CAMPIONI	1	2	3	4	5	6	7	8	9	10
ASCISSA	0.1	0.3	0.1	0.6	0.4	0.6	0.5	0.9	0.4	0.7
ORDINATA	0.1	0.4	0.5	0.9	0.2	0.3	0.6	0.2	0.4	0.6
CATEGORIA	A	A	A	A	A	B	B	B	B	B




FASE DI ADDESTRAMENTO



LOSS FUNCTION
DISCESA STOCASTICA DEL GRADIENTE
BACKPROPAGATION



UTILIZZO DELLA RETE




$$f(x) = f_4 \left(f_3 \left(f_2(x) \right) \right) \in \mathbb{R}^2$$





DEEP LEARNING – UN ESEMPIO PRATICO

Dopo la fase di training, si ottiene la suddivisione mostrata in Figura.



DEEP LEARNING – UN ESEMPIO PRATICO

Dopo la fase di training, si ottiene la suddivisione mostrata in Figura.





Se cambia il dataset aggiungendo un punto, e si aggiorna la rete, cambia il modo in cui si ottiene la classificazione finale.

DEEP LEARNING – UN ESEMPIO PRATICO

Dopo la fase di training, si ottiene la suddivisione mostrata in Figura.

CODICI DISPONIBILI SU


Higham,C.F., Higham,D.J.(2019) Deep learning: An introduction for applied mathematicians.



Se cambia il dataset aggiungendo un punto, e si aggiorna la rete, cambia il modo in cui si ottiene la classificazione finale.

LABORATORIO DI ANALISI NUMERICA

PROFESSORI




RICERCATORI



DOTTORANDI



ASSEGNISTI


$$A_N$$


ALCUNE COLLABORAZIONI PER TIROCINI E TESI ESTERNE



CENTRO ICT
per i Beni Culturali
Università di Salerno



**Agenzia Nazionale per le Nuove tecnologie,
l'Energia e lo Sviluppo economico sostenibile**





GRAZIE PER L'ATTENZIONE

